TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT TP. HCM
KHOA ĐÀO TẠO CHẤT LƯỢNG CAO

ĐỒ ÁN MÔN HỌC HỌC MÁY

TÌM HIỂU MỘT SỐ THUẬT TOÁN TRONG HỌC MÁY

GVHD: ThS. Trần Nhật Quang

SVTH: MSSV

Đào Xuân Thủy 16110544

Lâm Phước Bảo 16110016

Lớp thứ 6 – Tiết 1234

182MALE431085_01CLC

Tp. Hồ Chí Minh, tháng 5 năm 2019

NHẬN XÉT CỦA GIÁO VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Giáo viên hướng dẫn

ThS. Trần Nhật Quang

NHẬN XÉT CỦA GIÁO VIÊN PHẢN BIỆN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Giáo viên phản biện

……....

LỜI CẢM ƠN

Để hoàn thành đồ án môn học này, chúng em xin gửi lời cảm ơn chân thành đến thầy Trần Nhật Minh, người đã hỗ trợ và giúp đỡ chúng em trong suốt quá trình thực hiện đồ án, nhận xét và góp ý cũng như cung cấp tài liệu tham khảo, giúp chúng em có thể hoàn thành đồ án một cách tốt nhất. Nếu không có sự hướng dẫn và kinh nghiệm thực tiễn của thầy, chúng em nghĩ rằng đồ án môn học của chúng em khó có thể hoàn thiện và hoàn thành đúng thời hạn. Một lần nữa chúng em xin cảm ơn thầy.

Chúng em xin gửi lời cảm ơn đến các bạn cùng khóa đã cung cấp nhiều thông tin và kiến thức hữu ích giúp cho chúng em hoàn thiện đồ án này.

Đồ án này được thực hiện trong thời gian có hạn, cùng với kiến thức còn hạn chế và còn nhiều bỡ ngỡ khác, do đó thiếu sót là điều không thể tránh khỏi nên chúng em rất mong nhận được những ý kiến đóng góp quý báu của mọi người để kiến thức của chúng em được hoàn thiện hơn sau này. Chúng em xin chân thành cảm ơn.

Thành phố Hồ Chí Minh, ngày 19 tháng 05 năm 2019

Sinh viên thực hiện

Thuy Bao

Đào Xuân Thủy Lâm Phước Bảo

MỤC LỤC

DANH MỤC CÁC HÌNH 4
DANH MỤC CÁC BẢNG 5
MỘT SỐ THUẬT NGỮ SỬ DỤNG TRONG ĐỒ ÁN 6
CHƯƠNG 1: TÌM HIỂU VỀ ĐẠO VĂN 8
1. Đạo văn là gì? 8
2. Những điều nên làm 8
3. Những điều không nên làm 8
4. Lời cam đoan 8
CHƯƠNG 2: MULTIVARIATE LINEAR REGRESSION 10
1. Đôi nét lịch sử 10
2. Ứng dụng 10
3. Mô tả thuật toán 10
4. Lập trình thuật toán 12
CHƯƠNG 3: POLYNOMIAL REGRESSION 15
1. Đặt vấn đề 15
2. Ứng dụng 16
3. Mô tả thuật toán 16
3.1 Mô tả dữ liệu 16
3.2 Phương trình biểu diễn mô hình của thuật toán 17
3.3 Cách tính và đánh giá hiệu năng của mô hình 17
4. So sánh với các thuật toán khác 19
5. Lập trình thuật toán 20
5.1 Bộ dữ liệu cho thuật toán 20

5.2 Mục tiêu thuật toán 20
5.3 Thư viện sử dụng 21
5.3 Quá trình thực hiện 21
5.4 Kết quả thu được.....22
CHƯƠNG 4: LOGISTIC REGRESSION.....23
1. Đặt vấn đề.....23
2. Ứng dụng.....23
3. Mô tả thuật toán.....24
4. Lập trình thuật toán 26
4.1 Bộ dữ liệu cho thuật toán.....26
4.2 Mục tiêu thuật toán 26
4.3 Thư viện sử dụng 27
5.3 Quá trình thực hiện 27
5.4 Kết quả thu được.....28
CHƯƠNG 5: NEURAL NETWORKS 30
1. Đôi nét lịch sử 30
2. Ứng dụng.....30
3. Mô tả thuật toán.....31
4. Cài đặt thuật toán.....33
BẢNG PHÂN CÔNG CÔNG VIỆC.....38
PHỤ LỤC 39
1. Scikit-learn 39
2. Pandas.....39
3. Numpy.....39

4. Matplotlib 39
5. OS 39
TÀI LIỆU THAM KHẢO 42

DANH MỤC CÁC HÌNH

Hình 1. Biểu diễn tốc độ học 12

Hình 2. Mô hình Linear Regression 15

Hình 3. Sai số thuật toán Linear Regression 15

Hình 4. Vấn đề với Linear Regression 15

Hình 5. So sánh Linear Regression với Polynomial Regression.....16

Hình 6. Kết quả so sánh Polynomial Regression và Linear Regression 19

Hình 7. Overfitting với Linear Regression.....20

Hình 8. Overfitting với Polynomial Regression.....20

Hình 9. Mô tả dữ liệu mẫu cho thuật toán Polynomial Regression.....20

Hình 10. Kết quả thu được sau khi chạy thuật toán Polynomial Regression 22

Hình 11. Ví dụ về Logistic Regression 24

Hình 12. Mô hình Linear Regression cho dữ liệu rời rạc.....24

Hình 13. Áp dụng Sigmoid function cho thuật toán Logistic Regression.....25

Hình 14. Đường thẳng sigmoid khi được tinh chỉnh dữ liệu.....25

Hình 15. Mô tả dữ liệu mẫu cho thuật toán Logistic Regression.....26

Hình 16. Kết quả thu được sau khi chạy thuật toán Logistic Regression 28

Hình 17. Mạng nơ ron cơ bản.....31

Hình 18. Các ký hiệu sử trong mô tả Neural Network.....32

Hình 19. Sơ đồ neural network.....32

Hình 20. Sơ đồ hiện thực Model 36

Hình 21. Thành phần của keras 40

Hình 22. Module xây dựng Keras 41

DANH MỤC CÁC BẢNG

Bảng 1. Bảng mô tả dữ liệu cho Polynomial Regression với dữ liệu đơn chiều.....16

Bảng 2. Bảng mô tả dữ liệu cho Polynomial Regression với dữ liệu đa chiều.....16

MỘT SỐ THUẬT NGỮ SỬ DỤNG TRONG ĐỒ ÁN

Từ khóa	Ý nghĩa
fit	Định dạng / chỉnh sửa cho phù hợp
cost function	Sai số giữa kết quả thực tế và kết quả tìm được khi sử dụng thuật toán
underfitting	Mô hình tìm được bằng cách sử dụng thuật toán quá đơn giản, gây ra hiện tượng cost function lớn và khi áp dụng vào dữ liệu thực tế cho kết quả có độ sai số cao
overfitting	Mô hình tìm được bằng cách sử dụng thuật toán quá phức tạp, gây ra hiện tượng cost function nhỏ nhưng khi áp dụng vào dữ liệu thực tế thì cho kết quả có độ sai số cao
dataset	Bộ dữ liệu sử dụng cho thuật toán giúp thuật toán học được mô hình
learning rate	Chỉ số do lập trình viên thiết lập, giúp thuật toán chạy nhanh và tránh bị phân kỳ
Dense	Thư viện trong Keras, layer với full connection sử dụng như một layer neural network bình thường. Các tham số quan tâm: Activation: dùng để chọn activatio mong muốn Units: số lượng unit cho layer này use_bias: có sử dụng bias hay không (true hoặc false) input_dim: số lượng feature input. Cho layer đầu tiên
metrics	là thước đo để ta đánh giá accuracy của model.
loss functions	Sử dụng binary_crossentropy: dùng trong classifier 2 class
optimizers	dùng để chọn thuật toán training
plot_model	Giúp phác thảo cấu trúc model bằng hình ảnh (biểu đồ)

evaluate	để tính toán độ chính xác của model
compile	Sau khi build model xong thì compile nó có tác dụng biên tập lại toàn bộ model của chúng ta đã build. Ở đây chúng ta có thể chọn các tham số để training model như : thuật toán training thông qua tham số optimizer, function loss của model chúng ta có thể sử dụng mặc định hoặc tự build thông qua tham số loss, chọn metrics hiện thị khi model được training

CHƯƠNG 1: TÌM HIỂU VỀ ĐẠO VĂN

1. Đạo văn là gì?

Đạo văn với mức độ nghiên cứu khoa học của sinh viên có thể được hiểu là sử dụng công trình hay tác phẩm của người khác, lấy ý tưởng của người khác, sao chép nguyên bản từ ngữ của người khác mà không ghi nguồn, sử dụng cấu trúc và cách lí giải của người khác mà không ghi nhận họ, và lấy những thông tin chuyên ngành mà không đề rõ nguồn gốc.

Đạo văn được xem là hành vi thiếu trung thực về mặt học thuật và vi phạm đạo đức rất nghiêm trọng. Ở cấp độ sinh viên, đạo văn sẽ khiến kết quả nghiên cứu bị huỷ bỏ tuỳ thuộc vào mức độ nghiêm trọng của hành vi. Ở cấp độ nghiên cứu chuyên nghiệp, người đạo văn có thể bị buộc thôi việc, thu hồi công trình đã công bố hoặc huỷ bỏ chức danh.

2. Những điều nên làm

- Ghi rõ nguồn khi tham khảo tài liệu từ nguồn bên ngoài.
- Tôn trọng những sản phẩm, nội dung, công trình của người khác khi sử dụng.
- Nếu tài liệu muốn sử dụng quan trọng, cần xin ý kiến của chủ sử hữu trước khi sử dụng

3. Những điều không nên làm

- Sao chép công trình, tác phẩm mà không ghi rõ nguồn.
- Lấy ý tưởng của người khác để sử dụng cho mình.
- Sao chép cấu trúc và cách lý giải của người khác.

4. Lời cam đoan

Chúng em xin cam đoan đồ án này do chính chúng em thực hiện. Chúng em không sao chép, sử dụng bất kỳ tài liệu, mã nguồn của người khác mà không ghi rõ nguồn gốc. Chúng em xin chịu hoàn toàn trách nhiệm nếu vi phạm.

Thành phố Hồ Chí Minh, ngày 19 tháng 05 năm 2019

Sinh viên thực hiện

Thuy Bao

Đào Xuân Thủy Lâm Phước Bảo

CHƯƠNG 2: MULTIVARIATE LINEAR REGRESSION

1. Đôi nét lịch sử

Multivariate linear regression được trình bày bởi Legendre (1805) và Gauss (1809).

2. Ứng dụng

Ứng dụng của Multivariate linear regression tương tự như ứngg dụng của linear regression dùng để dự đoán các giá trị đầu ra có tính liên tục như dự đoán xu hướng, dự đoán về tài chính, kinh tế, nhà đất... Với MLR ta có thể đưa vào nhiều feature hơn dẫn đến độ chính xác tăng cao hơn.

3. Mô tả thuật toán

Định nghĩa: Multivariate linear regression (MLR) là một dạng của Linear regression với dữ liệu đầu vào có nhiều feature.

Công thức: có dạng là một hàm hypothesis với nhiều tham số là các feature x:

$$h_\theta(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 + \cdots + \theta_n x_n$$

Trong đó: $x_j^{(i)}$ là giá trị của feature j thứ i

$x^{(i)}$ là giá trị input (feature) thứ i

m là số lượng data traning

n là số lượng feature

Sử dụng định nghĩa của phép nhân ma trận, hàm hypothesis của MLR sẽ được biểu diễn như sau:

$$h_\theta(x) = \begin{bmatrix} \theta_0 & \theta_1 & \dots & \theta_n \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_n \end{bmatrix} = \theta^T x$$

Gradient Descent:

Cũng tương tự như Gradient Descent trong Linear Regression. Trong Multivariate linear regression có dạng:

$$
\begin{aligned}
&\text{repeat until convergence: } \{ \\
&\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_0^{(i)} \\
&\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_1^{(i)} \\
&\theta_2 := \theta_2 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_2^{(i)} \\
&\dots \\
&\}
\end{aligned}
$$

Chỉ cần lập lại "n" features

Một cách khác

$$
\begin{aligned}
&\text{repeat until convergence: } \{ \\
&\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_j^{(i)} \qquad \text{for j} := 0 \dots \text{n} \\
&\}
\end{aligned}
$$

Feature Scaling

Chúng ta có thể tăng tốc cho quá trình Gradient Descent bằng cách thay đổi giá trị input sắp xỉ cùng chung một khoảng nhỏ lại. Đó là bởi vì các giá trị θ sẽ giảm nhanh trong khoảng số nhỏ lại. Thông thường thì các giá trị hay nằm trong các khoảng $-1 \leq x_{(i)} \leq 1$ hoặc $-0.5 \leq x_{(i)} \leq 0.5$

Có 2 kĩ thuật để sử dụng đó là: feature scaling và mean normalization

Learning Rate (tốc độ học):

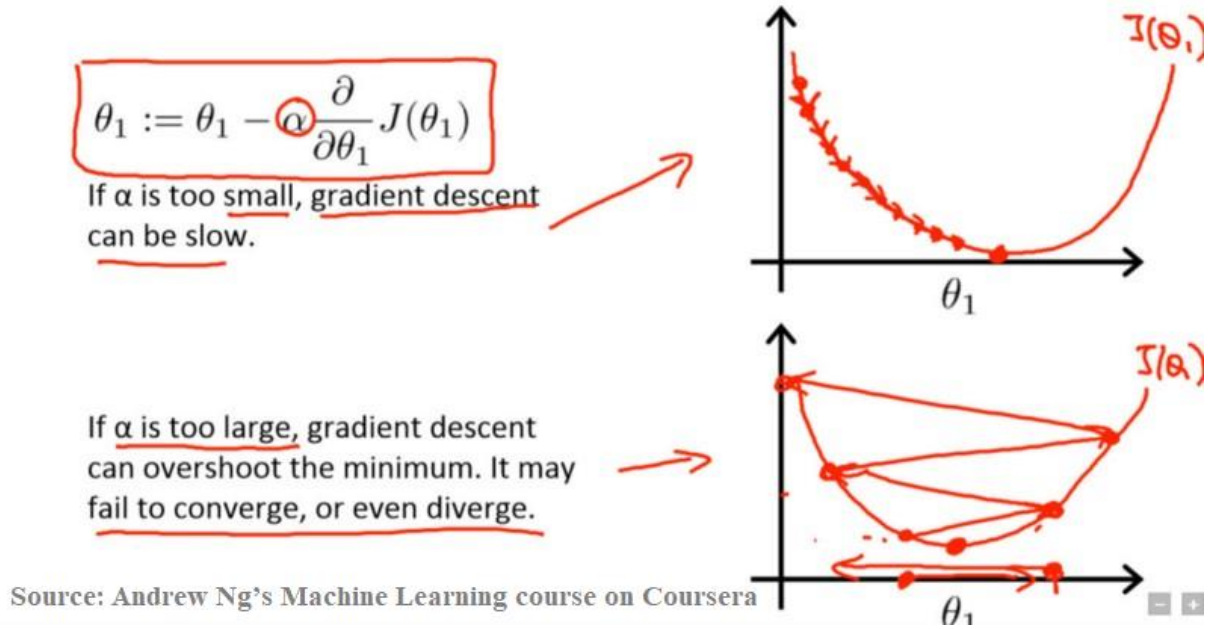

Hình 1. Biểu diễn tốc độ học

Nhìn vào trong hình ta có thể thấy ở hình đầu tiên khi trong quá trình lập của Gradient descent nếu hệ số alpha của learning rate quá bé sẽ làm chậm tốc độ đi về điểm min. Tuy nhiên với trường hợp ngược lại nếu hệ số learning rate lớn có thể làm cho hàm đi mãi mà khong bao giờ hội tụ.

Vì vậy mà lựa chọn hệ số cho learning rate vô cùng quan trọng. thông thường learning rate thường chọn nhỏ.

4. Lập trình thuật toán

Bước 1: Load dữ liệu và xử lí dữ liệu

Dữ liệu được load có tên Startups.csv, gồm 5 cột:

- R&D spend: chi phí R&D
- Adminstration: chi phí quản trị
- Marketing spend: chi phí marketing
- State: tên bang. Trong dataset chỉ bao gồm 3 bang: New York, California và Florida
- Profit: Lợi nhuận

```
# Importing the dataset
dataset = pd.read_csv('Dataset\Startups.csv')
#bỏ cột cuối Profit
X = dataset.iloc[:, :-1]
#lấy cột 4: profit
y = dataset.iloc[:, 4]
```

Ta lấy được data train gán vào X, và label gán vào y.

Tuy nhiên vì dữ liệu ở cột State là chữ nên chúng ta tiến hành chuyển đổi về dạng số

```
#chuyển trang binary vector theo index, bỏ cột  California
states=pd.get_dummies(X['State'],drop_first=True)
```

Sau khi xử lí xong cột State về dạng số ta tiến hành gán lại vào data training là X

```
#column name:  Index | R&D Spend | Admin | Marketing Spend | Floria | New York
X=pd.concat([X,states],axis=1)
```

Lúc này trong X sẽ có 5 feature bao gồm: R&D spend, admin, Marketing spend, florida và new york

Bước 2: Tiến hành tách dữ liệu training và test

```
# Splitting the dataset into the Training set and Test set
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.2, random_state = 0)
```

Dữ liệu đã được tách ra thành train và test từ X và y lúc nãy. Với hàm phân chia ngẫu nhiên và tập dữ liệu test chỉ 20% trong X

Bước 3: Traing

```
#Fitting Multiple Linear Regression to the Training set
from sklearn.linear_model import LinearRegression
regressor = LinearRegression()
regressor.fit(X_train, y_train)
```

Bước 4: Đánh giá Model

```
# Predicting the Test set results
# y dự đoán ( do model dự đoán )
y_pred = regressor.predict(X_test)
# y kết quả thực tách từ dataset ra
score=r2_score(y_test,y_pred)
print('score: '+str(score))
```

Sử dụng dữ liệu X test lúc nãy đã tách là input cho hàm Predict của model. Sau khi model đã dự đoán xong ta sẽ lấy kết quả đó đi so sánh với label test đã lấy ra lúc trước từ đó mà thu được độ chính xác của model đã train

CHƯƠNG 3: POLYNOMIAL REGRESSION

1. Đặt vấn đề

Để biểu diễn một đồ thị học được, Linear Regression sử dụng hàm số tuyến tính (được biểu diễn dưới dạng một đường thẳng trên đồ thị) làm hàm tiên đoán (ký hiệu h(x)).

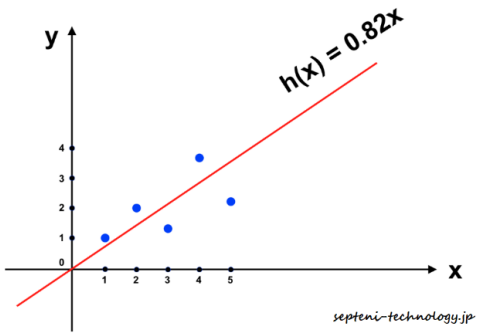

Hình 2. Mô hình Linear Regression

Từ đó, sai số của h(x) được tính toán dựa trên bình phương sai khác giữa h(x) và y thực tế như hình sau:

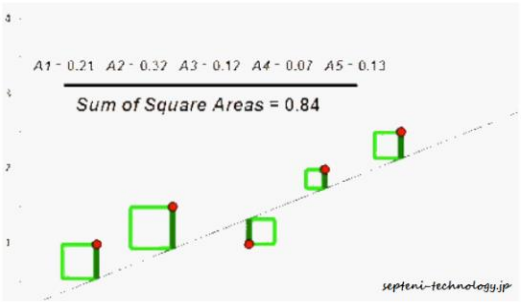

Hình 3. Sai số thuật toán Linear Regression

Nhưng nếu ta áp dụng mô hình Linear Regression trong trường hợp sau:

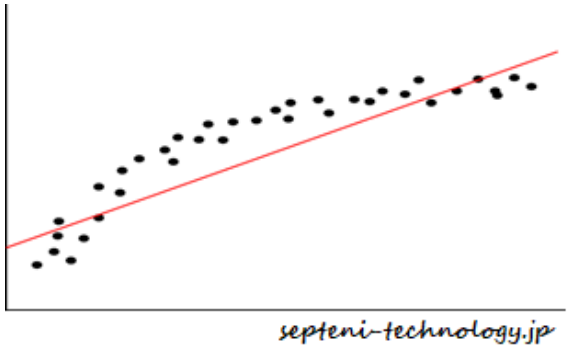

Hình 4. Vấn đề với Linear Regression

Trong trường hợp này dữ liệu không tập trung quanh đường thẳng h(x) mà có hơi hướng theo dạng đường cong hơn. Chính vì thế, khi sử dụng hàm h(x) này, kết quả dự đoán sẽ không tốt. Khi mô hình không đáp ứng được xu hướng biến thiên của dự liệu, ta sẽ gặp phải vấn đề như trên, chúng được gọi là "underfitting". Quá trình ta cần làm thực chất là điều chỉnh hàm số phù hợp với sự biến thiên của dữ liệu, nên khi hàm số không biến thiên theo xu hướng của dữ liệu thì mô hình sẽ không khớp với dữ liệu. Khi gặp vấn đề này chúng ta cần hàm số phức tạp hơn để hàm tiên đoán h(x) đạt hiệu quả tốt hơn.

2. Ứng dụng

Để giải quyết bài toán trên, thay vì dùng đường thẳng để mô tả sự biến thiên của dữ liệu, ta sẽ tăng bậc của phương trình để giải quyết hiện tượng "underfitting". Đồ thị sẽ có dạng bậc cao hơn và phức tạp hơn, để mô tả chính xác hơn sự biến thiên của dữ liệu và "cost function" ta thu được sẽ nhỏ hơn. Từ đó, ta thu được một mô hình mô tả dữ liệu chính xác hơn. Ta gọi đó là thuật toán Polynomial Regression.

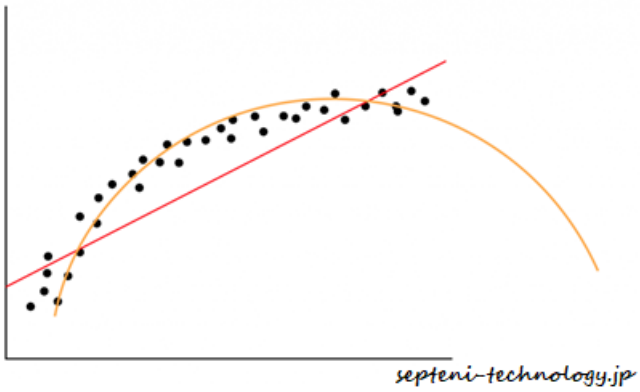

Hình 5. So sánh Linear Regression với Polynomial Regression

3. Mô tả thuật toán

3.1 Mô tả dữ liệu

Từ thực tế, ta có thể biểu diễn mô hình dữ liệu dưới dạng như sau:

Bảng 1. Bảng mô tả dữ liệu cho Polynomial Regression với dữ liệu đơn chiều

Dữ liệu đầu vào	Kết quả đạt được
x_1	y_1
x_2	y_2
x_3	y_3
x_4	y_4
…	…

Bảng 2. Bảng mô tả dữ liệu cho Polynomial Regression với dữ liệu đa chiều

Dữ liệu đầu vào		Kết quả đạt được
x_{11}	x_{21}	y_1
x_{12}	x_{22}	y_2
x_{13}	x_{23}	y_3
x_{14}	x_{24}	y_4
…	…	…

3.2 Phương trình biểu diễn mô hình của thuật toán

Từ bảng mô tả dữ liệu trên, để xây dựng mô hình mô tả sự biến thiên của dữ liệu loại tăng dần sử dụng Polynomial Regression, ta có phương trình dưới dạng:

- Dữ liệu một chiều:

$$h_\theta(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_1^2$$

- Dữ liệu nhiều chiều:

$$h_\theta(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 x_2 + \theta_4 x_1 x_2^2 + \dots$$

Bước tiếp theo, biến đổi phương trình biểu diễn mô hình Polynomial Regression về phương trình có dạng của thuật toán Linear Regression:

- Đặt các thành phần biến trong phương trình thành biến mới.
- Viết lại phương trình tương đương mới có dạng của phương trình đường thẳng.
- Phương trình tổng quát sau khi biến đổi có dạng:

$$h_\theta(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 + \theta_4 x_4 + \theta_5 x_5 + \theta_6 x_6 + \dots + \theta_n x_n$$

n: số lượng phần tử trong phương trình ban đầu

3.3 Cách tính và đánh giá hiệu năng của mô hình

Với dữ liệu như trên, ta có thể mô tả dữ liệu theo phương trình biểu diễn như sau:

$$\begin{bmatrix} x_{11} & x_{12} & x_{13} & \dots \\ x_{21} & x_{22} & x_{23} & \dots \\ \dots & \dots & \dots & \dots \\ x_{m1} & x_{m2} & x_{m3} & \dots \end{bmatrix} \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \dots \\ \theta_n \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_m \end{bmatrix}$$

với m là số dòng dữ liệu trong dataset, n là số phần tử trong phương trình biểu diễn mô hình.

X θ y

Để tìm những tham số θ của phương trình, ta có nhiều cách:

Cách 1: Normal Equation

Với ma trận trên, ta có phương trình:

$X.\theta = y \leftrightarrow X^T.X.\theta = X^T.y$

$\leftrightarrow (X^T.X)^{-1}.X^T.X.\theta = (X^T.X)^{-1}.X^T.y$

$\leftrightarrow \theta = (X^T.X)^{-1}.X^T.y$

Cách 2: Gradient descent

Lặp lại tới khi hội tụ
{
$\theta_j := \theta_j - \alpha \frac{\partial}{\partial.\theta_j} J(\theta)$
}
	j = $\overline{0,m}$: m là số lượng θ trong công thức
	α: learning rate

Một số thuật toán khác như: Conjugate gradient, BFGS, L_BFGS…

Để đánh giá hiệu năng của thuật toán, ta sử dụng cost function:

$$J(\theta) = \frac{1}{2n} \sum_{i=1}^{n} (h_\theta(y_{predict}^{(i)} - y_{result}^{(i)}))^2$$

n: số lượng dòng dữ liệu trong dataset

$y_{predict}^{(i)}$: kết quả do thuật toán tính ra dựa trên dữ liệu đầu vào tại dòng thứ i

$y_{result}^{(i)}$: kết quả thực tế trong dữ liệu đầu vào tại dòng thứ i

4. So sánh với các thuật toán khác

Như vậy, ta có thể thấy thuật Polynomial Regression là biểu đồ mô tả sự biến thiên dữ liệu tốt hơn so với Linear Regression trong trường hợp này. Từ đó cost function với thuật toán này sẽ thấp hơn và sự chính xác cao hơn.

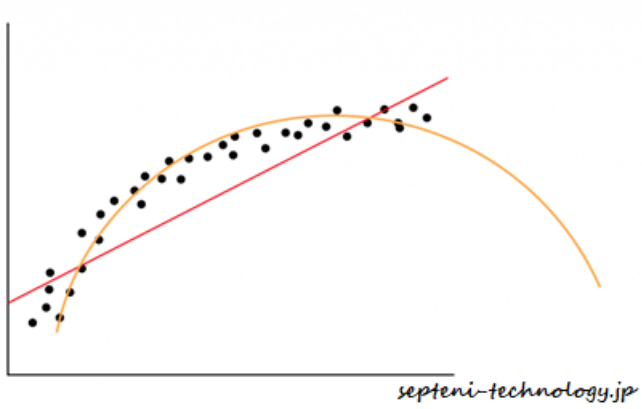

Hình 6. Kết quả so sánh Polynomial Regression và Linear Regression

Tuy vậy, không phải khi nào Polynomial Regression cũng tốt hơn Linear Regression. Với bài toán có dữ liệu biến thiên phức tạp, đòi hỏi phương trình có bậc cao hơn để mô tả. Nhưng bên cạnh đó, một số dữ liệu biến thiên tuyến tính, khi đó Linear Regression đủ để mô tả khối dữ liệu đó, nếu ta dùng Polynomial Regression, bậc của phương trình cao hơn, ta sẽ gặp hiện tượng overfitting. Hoặc ta áp dụng bậc cho phương trình cao hơn so với bậc cần tìm, ta cũng gây hiện tượng overfitting Hiện tượng này sẽ tìm ra cost function nhỏ, nhưng khi áp dụng vào dữ liệu kiểm tra, sai số sẽ rất lớn.

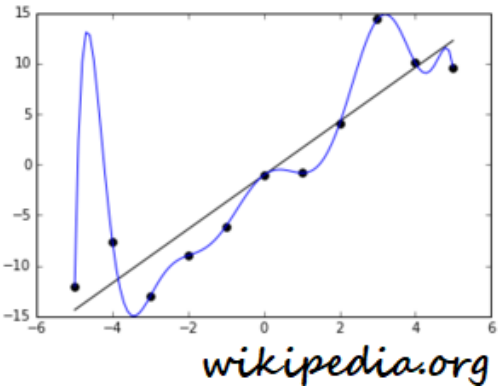

Hình 7. Overfitting với Linear Regression

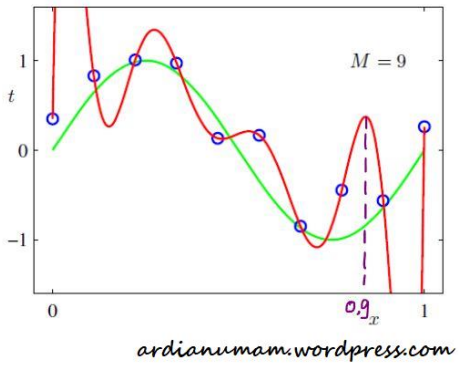

Hình 8. Overfitting với Polynomial Regression

5. Lập trình thuật toán

5.1 Bộ dữ liệu cho thuật toán

- Chủ đề: Dự đoán lương của nhân viên dựa theo cấp bậc vị trí.
- Địa chỉ tải về: https://www.kaggle.com/testpython/polynomial-position-salary-data.
- Số dòng dữ liệu cho thuật toán: 10.

Position	Level	Salary
Business Analyst	1	45000
Junior Consultant	2	50000
Senior Consultant	3	60000
Manager	4	80000
Country Manager	5	110000
Region Manager	6	150000
Partner	7	200000
Senior Partner	8	300000
C-level	9	500000
CEO	10	1000000

Hình 9. Mô tả dữ liệu mẫu cho thuật toán Polynomial Regression

5.2 Mục tiêu thuật toán

Dự đoán lương của nhân viên dựa theo cấp bậc vị trí của họ trong công ty sử dụng Polynomial Regression và so sánh mức độ hiểu quả với thuật toán Lineal Regresison.

5.3 Thư viện sử dụng

- Scikit-learn (Phụ lục - Mục 1).
- Pandas (Phụ lục - Mục 2).
- Numpy (Phụ lục - Mục 3).
- Matplotlib (Phụ lục - Mục 4).
- OS (Phụ lục - Mục 5).

5.3 Quá trình thực hiện

Bước 1: Khai báo nơi lưu trữ dataset.

```
import os
import pandas as pd # data processing, CSV file I/O (e.g. pd.read_csv)
ROOT_DIR = os.path.dirname(os.path.abspath(__file__))
CONFIG_PATH = os.path.join(ROOT_DIR, 'datasets')
data = pd.read_csv(CONFIG_PATH + '/Position_Salaries.csv')
```

Bước 2: Khai báo thứ tự dữ liệu đầu vào X là cột 1 và 2, dữ liệu đầu ra cần đạt được là cột cuối cùng (cột 3).

```
X = data.iloc[:,1:2].values
y = data.iloc[:,-1].values
```

Bước 3: Căn giữa dữ liệu về giá trị trung bình bằng 0 và biến đổi dữ liệu đầu vào về dạng Polynomial, khai báo hai kiểu model có dạng Linear Regression và truyền, tinh chỉnh bộ dữ liệu đầu vào cho hai model.

```
from sklearn.preprocessing import PolynomialFeatures
poly_reg = PolynomialFeatures(degree = 2)
X_poly = poly_reg.fit_transform(X)

from sklearn.linear_model import LinearRegression
linear_reg_model = LinearRegression()
linear_reg_model.fit(X, y)

poly_reg_model = LinearRegression()
poly_reg_model.fit(X_poly, y)
```

Bước 4: Sử dụng thư viện Matplotlib vẽ hai sơ đồ học được bằng hai thuật toán Linear và Polynimial cho người dùng, đồng thời chấm các điểm cho kết quả thực tế từ dữ liệu đầu vào lên sơ đồ.

```
import matplotlib.pyplot as plt
plt.scatter(X, y, color='red', label='Actual observation points')
plt.plot(X, linear_reg_model.predict(X), label='Linear regressor fit
curve')
plt.plot(X, poly_reg_model.predict(poly_reg.fit_transform(X)),
label='Polynmial regressor fit line')
```

```
plt.title('Truth or bluff (Linear Regression)')
plt.xlabel('Position Level')
plt.ylabel('Salary')

plt.legend()
plt.show()
```

5.4 Kết quả thu được

Kết quả thu được được mô tả như hình dưới đây:

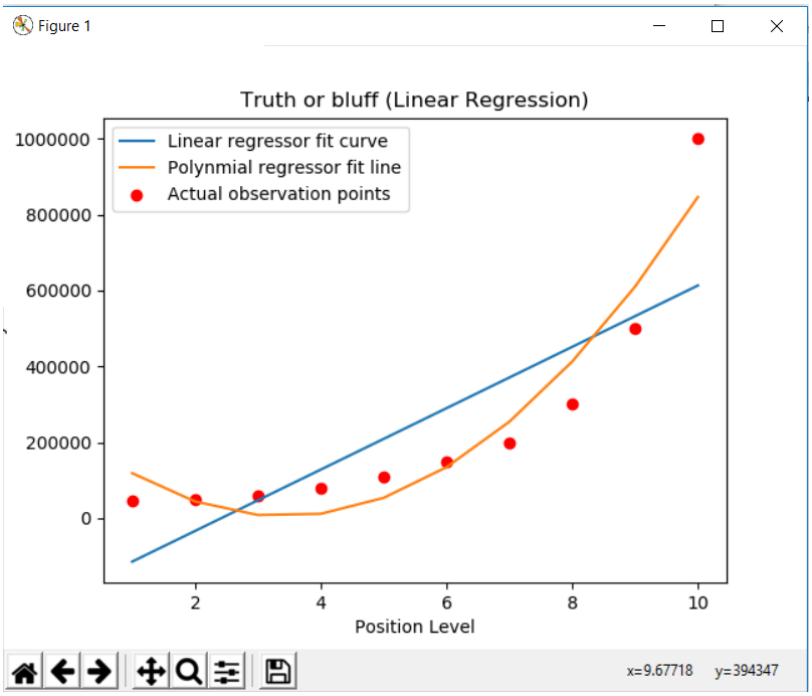

Hình 10. Kết quả thu được sau khi chạy thuật toán Polynomial Regression

Như ta đã thấy, nếu sử dụng thuật toán Linear Regression, sơ đồ học ra sẽ cho cost function rất lớn và không thể mô tả đúng được sự biến thiên của dữ liệu. Nếu dùng thuật toán Polynomial Regression, sơ đồ học ra sẽ biến thiên theo đường parabol và mô tả chính xác hơn sự biến thiên của dữ liệu.

CHƯƠNG 4: LOGISTIC REGRESSION

1. Đặt vấn đề

Như ở những thuật toán trên, ta có thể thấy dữ liệu đầu ra ta muốn đạt được là liên tục. Vậy với những kiểu giá trị rời rạc thì phải làm như thế nào?

Với những kiểu dữ liệu mà giá trị dự đoán đầu ra như sau:

- Dự đoán một email có phải là email spam hay không. Kết quả đầu ra là có hoặc không.
- Phân loại email thuộc nhóm e mail nào. Kết quả đầu ra là nhóm bạn, nhóm công việc, nhóm học tập, nhóm quảng cáo.
- Phân nhóm ảnh. Kết quả đầu ra có thể là nhóm động vật, cây cối hoặc nhóm con người.

Ở những ví dụ trên, ta thấy kết quả mong muốn của ta không phải là một giá trị liên tục mà đó là một nhóm giá trị rời rạc. Vậy để giải quyết bài toán này, ta sẽ sử dụng thuật toán Logistic Regression.

2. Ứng dụng

Mô hình hồi quy Logistic sẽ dùng hàm biến đổi logarit cho biến đầu ra để biến mô hình từ quan hệ phi tuyến tính sang tuyến tính. Nói một cách khác, nó biểu diễn quan hệ hồi quy tuyến tính dưới dạng hàm logarit, nên đôi khi nó cũng được gọi là Logit Regression [2].

Mô hình Logistic có một giả định rằng biến phụ thuộc (dự đoán) có giá trị rời rạc. Nếu biến dự đoán chỉ lấy hai giá trị rời rạc, đó là mô hình Binary Logistic Regression. Nếu biến dự đoán lấy nhiều hơn hai giá trị, đó là mô hình Multinomial Logistic Regression.

Ví dụ, xem một bức ảnh có phải là ảnh chân dung hay không. Thì ở đây ta coi đầu ra y = 1 nếu bước ảnh có mặt con người và y = 0 nếu bức ảnh không có mặt người nào. Đầu vào x ở đây sẽ là các pixel một bức ảnh đầu vào.

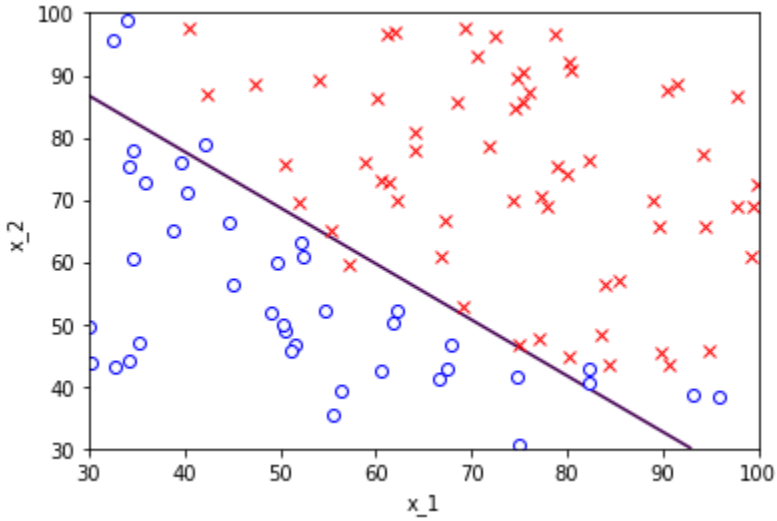

Hình 11. Ví dụ về Logistic Regression

3. Mô tả thuật toán

Đầu tiên, ta dùng Linear Regression để dự đoán y khi biết x. Ở đây ta bỏ qua điều kiện giá trị của y là rời rạc (0 hoặc 1). Ở Linear Regression ta có hàm dự đoán:

$$h_\theta(x) = g(\theta^T x)$$

Sau khi thực hiện chạy dữ liệu dưới thuật toán Linear Regression, ta được mô hình có dạng như sau:

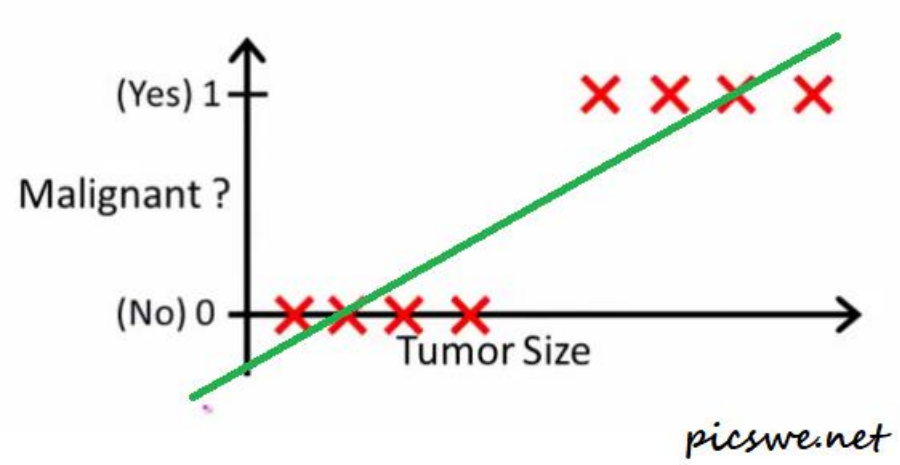

Hình 12. Mô hình Linear Regression cho dữ liệu rời rạc

Vì giá trị đầu ra là rời rạc, nên ta giới hạn y trong đoạn [0, 1]. Do vậy, ta sử dụng kết hợp sigmoid function (logistic function) $h_\theta(x) = g(\theta^T x)$, trong đó:

$$g(z) = \frac{1}{1 + e^{-z}} \text{ với } z \in R$$

Tóm lại, ta có hàm dự đoán với đầu vào x như sau:

$$h_\theta(x) = \frac{1}{1 + e^{-\theta^T x}}$$

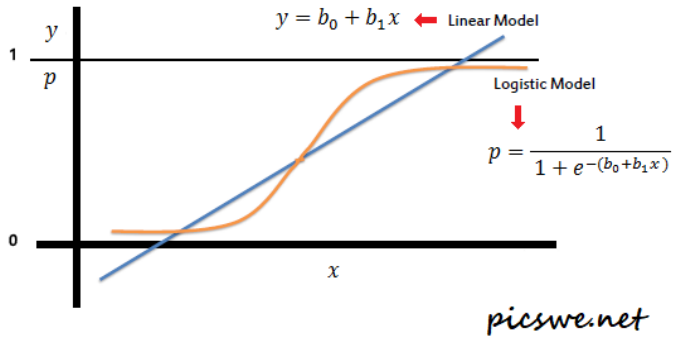

Hình 13. Áp dụng Sigmoid function cho thuật toán Logistic Regression

Nếu ban đầu, ta chỉnh sửa dữ liệu với giá trị trung bình là 0, ta sẽ được mô hình có trục Oy nằm giữa, từ đó dựa trên hàm sigmoid, ta có thể dễ dàng đoán dữ liệu đầu vào sẽ thuộc nhóm nào, cụ thể nếu kết quả tính được nhỏ hơn 0.5, dữ liệu đó sẽ thuộc nhóm 0, và nếu lớn hơn 0.5, dữ liệu đó sẽ thuộc nhóm 1.

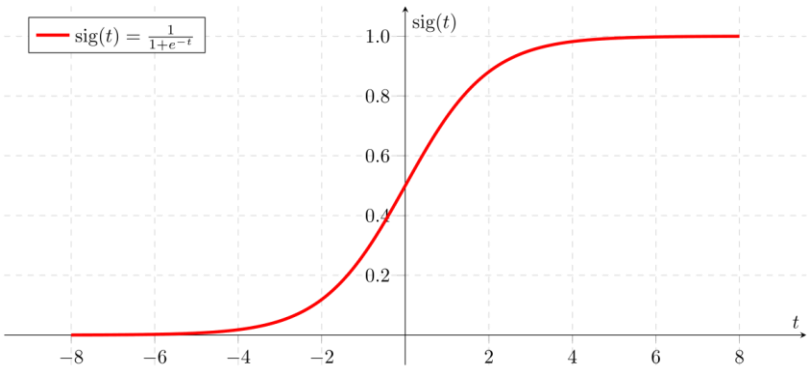

Hình 14. Đường thẳng sigmoid khi được tinh chỉnh dữ liệu

Để tính cost function, ta sử dụng hàm sau:

$$J(\theta) = \frac{1}{m}\sum_{i=1}^{m}(-y^{(i)}.\log(h_\theta(x^{(i)})) - (1 - y^{(i)}).\log(1 - h_\theta(x^{(i)})))$$

Để tìm θ giúp hàm $J(\theta)$ có giá trị nhỏ nhất, ta cần tìm điểm cực tiểu của phương trình $J(\theta)$, ta có thể sử dụng Gradient descent:

Lặp lại tới khi hội tụ
{
$\theta_j := \theta_j - \alpha \frac{\partial}{\partial.\theta_j} J(\theta)$
}
	j = $\overline{0,m}$: m là số lượng θ trong công thức
	α: learning rate

Một số phương pháp khác như: Newton-Raphson, Conjugate gradient, BFGS, L_BFGS…

4. Lập trình thuật toán

4.1 Bộ dữ liệu cho thuật toán

- Chủ đề: Lịch sử thanh toán cho quảng cáo của người dùng Facebook dựa trên độ tuổi và mức lương ước tính.
- Địa chỉ tải về: https://www.kaggle.com/rakeshrau/social-network-ads.
- Số dòng dữ liệu cho thuật toán: 400.

User ID	Gender	Age	EstimatedSalary	Purchased
15624510	Male	19	19000	0
15810944	Male	35	20000	0
15668575	Female	26	43000	0
15603246	Female	27	57000	0
15804002	Male	19	76000	0
15728773	Male	27	58000	0
15598044	Female	27	84000	0
15694829	Female	32	150000	1
15600575	Male	25	33000	0

Hình 15. Mô tả dữ liệu mẫu cho thuật toán Logistic Regression

4.2 Mục tiêu thuật toán

Dự đoán quyết định thanh toán cho dịch vụ quảng cáo Facebook dựa trên độ tuổi và mức lương ước tính từ người dùng.

4.3 Thư viện sử dụng

- Scikit-learn (Phụ lục - Mục 1).
- Pandas (Phụ lục - Mục 2).
- Numpy (Phụ lục - Mục 3).
- Matplotlib (Phụ lục - Mục 4).
- OS (Phụ lục - Mục 5).

5.3 Quá trình thực hiện

Bước 1: Khai báo nơi lưu trữ dataset và bỏ cột User ID và cột Gender

```
ROOT_DIR = os.path.dirname(os.path.abspath(__file__))
CONFIG_PATH = os.path.join(ROOT_DIR, 'datasets')
print(os.listdir(CONFIG_PATH))

data = pd.read_csv(CONFIG_PATH + '/Social_Network_Ads.csv')
#print(data)
data.drop(columns=['User ID','Gender',],axis=1,inplace=True)
data.head()
```

Bước 2: Khai báo thứ tự dữ liệu đầu vào X là tất cả các cột trừ cột cuối (cột 1 và 2), dữ liệu đầu ra cần đạt được là cột cuối cùng (cột 3).

```
y = data.iloc[:,-1].values
X = data.iloc[:,:-1].values
```

Bước 3: Sử dụng thư việc scikit-learn lấy 25% dữ liệu làm dữ liệu kiểm tra và chỉnh sửa lại dữ liệu để học về giá trị trung bình là 0, sau đó chuyển đổi cả 2 gói dữ liệu.

```
# Phân tách dữ liệu
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size =
0.25, random_state = 0)

# Phân tách dữ liệu
from sklearn.preprocessing import StandardScaler
sc = StandardScaler()
X_train = sc.fit_transform(X_train)
X_test = sc.transform(X_test)
```

Bước 4: Chỉnh sửa lại gói dữ liệu đầu vào và tính hiệu năng của thuật toán.

```
from sklearn.linear_model import LogisticRegression
classifierLR = LogisticRegression()
classifierLR.fit(X_train, y_train)

from sklearn.metrics import accuracy_score
y_predLR=classifierLR.predict(X_test)
print(accuracy_score(y_test, y_predLR))
```

Bước 4: Sử dụng thư viện Matplotlib vẽ sơ đồ học được bằng thuật toán Logistic Regression cho người dùng xem, đồng thời chấm các điểm cho kết quả thực tế từ dữ liệu đầu vào lên sơ đồ.

```
from matplotlib.colors import ListedColormap
X_set, y_set = X_train, y_train
X1, X2 = np.meshgrid(np.arange(start = X_set[:, 0].min() - 1, stop =
X_set[:, 0].max() + 1, step = 0.01),
                     np.arange(start = X_set[:, 1].min() - 1, stop =
X_set[:, 1].max() + 1, step = 0.01))
plt.contourf(X1, X2, classifierLR.predict(np.array([X1.ravel(),
X2.ravel()]).T).reshape(X1.shape),
             alpha = 0.75, cmap = ListedColormap(('red', 'green')))
plt.xlim(X1.min(), X1.max())
plt.ylim(X2.min(), X2.max())
for i, j in enumerate(np.unique(y_set)):
    plt.scatter(X_set[y_set == j, 0], X_set[y_set == j, 1],
                c = ListedColormap(('red', 'green'))(i), label = j)
plt.title('Logistic Regression (Training set)')
plt.xlabel('Age')
plt.ylabel('Estimated Salary')
plt.legend()
plt.show()
```

5.4 Kết quả thu được

Thuật toán chạy với hiệu suất đạt 89%.

Kết quả thu được được mô tả như hình dưới đây:

Hình 16. Kết quả thu được sau khi chạy thuật toán Logistic Regression

Như ta đã thấy, thuật toán đã học với độ chính xác 89%, và đã chia dataset thành hai khu vực.

CHƯƠNG 5: NEURAL NETWORKS

1. Đôi nét lịch sử

Vào năm 1957, Frank Rosenblatt đã thiết kế mạng nơron (neural network) đầu tiên cho máy tính, trong đó mô phỏng quá trình suy nghĩ của bộ não con người.

Vào năm 2011, 2011 - Google Brain đã được phát triển, và mạng deep nơron (deep neural network) của nó có thể học để phát hiện và phân loại nhiều đối tượng theo cách mà một con mèo thực hiện. [3]

2. Ứng dụng

Mạng nơ ron là một tập các thuật toán, được mô hình hóa theo não bộ con người, được tạo ra để nhận diện các khuôn mẫu, hình mẫu của tập dữ liệu. Nó cố gắng hiểu ý nghĩa của từng dòng dữ liệu thông qua các thuật toán tạo nên sự nhận thức cho máy móc bằng những loại dữ liệu đã được dán nhãn cho đến những dữ liệu thô chưa được xác định. Kết quả mà mạng nơ ron có thể nhận diện ra chính là những con số, bao gồm các vectors và dĩ nhiên những con số đó đều được ánh xạ đến dữ liệu hiện thực của con người như là hình ảnh, âm thanh, đoạn văn, thời gian.

Mạng nơ ron giúp ta gom nhóm và phân loại. Chúng ta có thể tưởng tượng rằng chúng là những cố máy có linh hồn và nhận thức được kết quả mà chúng ta mong muốn sau khi đã dạy chúng học thông qua hàng loạt các dữ liệu mẫu.

3. Mô tả thuật toán

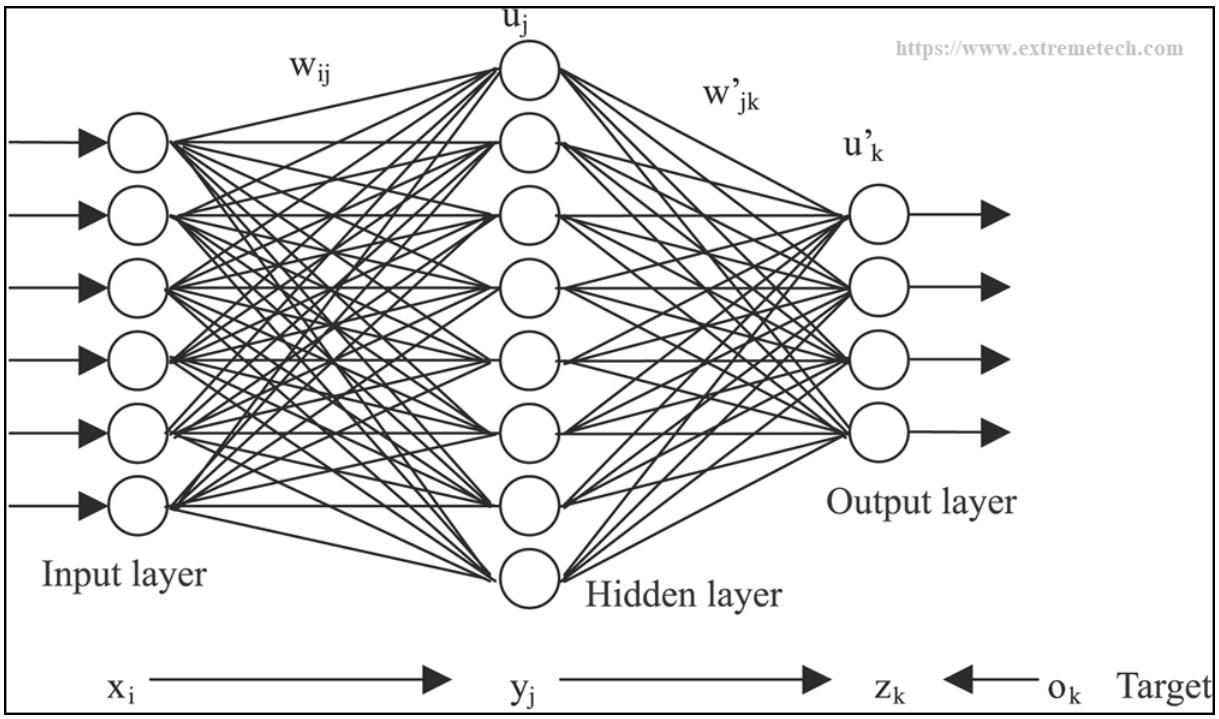

Hình 17. Mạng nơ ron cơ bản

Các thành phần trong mạng Nơ ron:

Các lớp:

Input layer: Lớp đầu tiên trong mạng nơ ron, thông thường số unit của lớp chính là số lượng feature chúng ta đưa vào.

Hidden layer: Lớp nằm giữa Input layer và Output Layer, có thể có nhiều Hidden layer với số unit khác nhau tùy độ phức tạp của bài toán và dữ liệu cần xử lí. Nơi đây tiếp nhận input từ các Node (ví dụ input layer) và tiến hành xử lí tính toán.

Output layer: Lớp cuối cùng trong mạng nơ ron, nơi đây tiếp nhận input từ các output đã được xử lí ở tầng hidden layer và tiến hành tính toán lần cuối để cho ra kết quả. Số lượng unit ở tầng này phụ thuộc vào số lượng label mà chúng ta muốn.

Units: Một node hình tròn trong một layer được gọi là một unit. Unit ở các input layer, hidden layers, và output layer được lần lượt gọi là input unit, hidden unit, và output unit. Đầu vào của các hidden layer được ký hiệu bởi **z**, đầu ra của mỗi unit thường được ký hiệu là **a** (thể hiện activation, tức giá trị của mỗi unit sau khi ta áp dụng activation function lên **z**). Đầu ra của unit thứ **i** trong layer thứ l được kí hiệu $\mathbf{a}_i^{(l)}$

Giả sử thêm rằng số unit trong layer thứ l (không tính bias) là $d^{(l)}$. Vector biểu diễn output layer thứ l được kí hiệu là $a^{(l)}$ thuộc $R^{d(l)}$

Activation functions

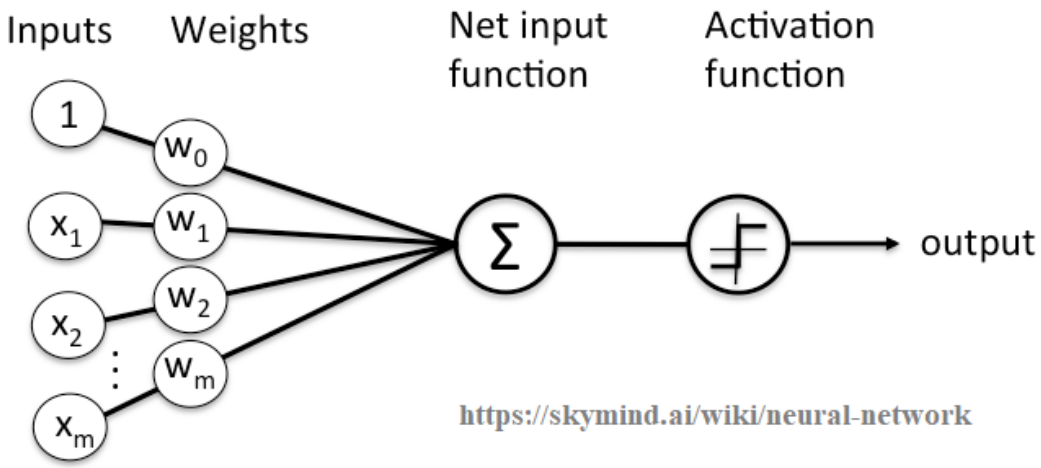

Hình 18. Các ký hiệu sử trong mô tả Neural Network

Mỗi output của một unit (trừ các input units) được tính dựa vào công thức:

$$a_i^{(l)} = f(\mathbf{w}_i^{(l)T}\mathbf{a}^{(l-1)} + b_i^{(l)})$$

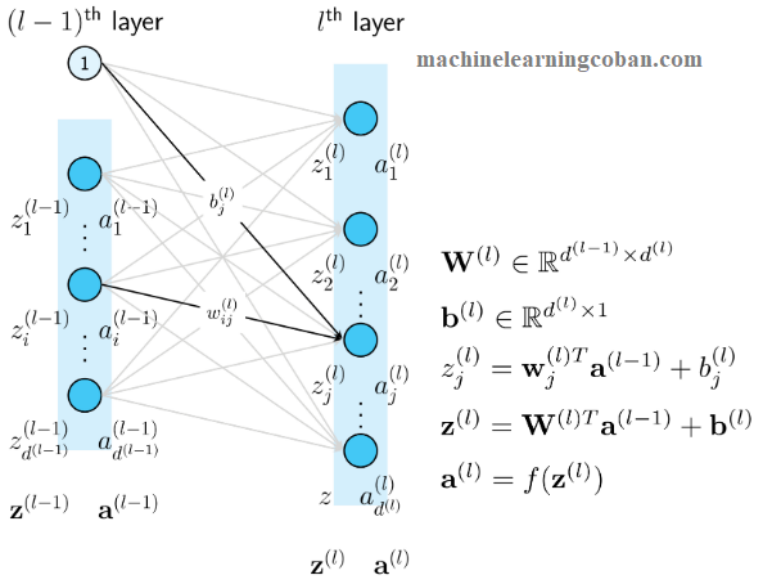

Hình 19. Sơ đồ neural network

Trong đó f(.) là một (nonlinear) activation function. Ở dạng vector, biểu thức bên trên được viết là:

$$\mathbf{a}^{(l)} = f(\mathbf{W}^{(l)T}\mathbf{a}^{(l-1)} + \mathbf{b}^{(l)})$$

Khi activation function f(.) được áp dụng cho một ma trận (hoặc vector), ta hiểu rằng nó được áp dụng cho từng thành phần của ma trận đó. Sau đó các thành phần này được sắp xếp lại đúng theo thứ tự để được một ma trận có kích thước bằng với ma trận input. Trong tiếng Anh, việc áp dụng lên từng phần tử như thế này được gọi là element-wise.

Backpropagation

Lan truyền ngược (backpropagation) là giải thuật cốt lõi giúp cho các mô hình học sâu có thể dễ dàng thực thi tính toán được. Với các mạng NN hiện đại, nhờ giải thuật này mà thuật toán tối ưu với đạo hàm (gradient descent) có thể nhanh hơn hàng triệu lần so với cách thực hiện truyền thống.

Forward propagation

Như bạn thấy thì tất cả các nốt mạng (nơ-ron) được kết hợp đôi một với nhau theo một chiều duy nhất từ tầng vào tới tầng ra. Tức là mỗi nốt ở một tầng nào đó sẽ nhận đầu vào là tất cả các nốt ở tầng trước đó mà không suy luận ngược lại.

4. Cài đặt thuật toán

Trong phần trình bày cài đặt thuật toán Neural Networks của nhóm em, nhóm em sẽ sử dụng thư viện Keras để hỗ trợ quá trình cài đặt

Chúng ta sẽ đi qua các bước sau để tiến hành cài đặt thuật toán:

- Bước 1: Load dữ liệu
- Bước 2: Thiết lập Model
- Bước 3: Compile Model
- Bước 4: Train Model
- Bước 5: Đánh giá Model
- Bước 6: Dự đoán dữ liệu

Load dữ liệu

Trong phần project của nhóm, nhóm sẽ sử dụng dataset chuẩn đoán bệnh tim được lấy từ Kaggle

https://www.kaggle.com/ronitf/heart-disease-uci

Phân tích về tập dữ liệu :

Gồm 13 cột đại diện cho từng đặc điểm của người bệnh:

> 1. Age: tuổi

> 2. Sex: giới tính

> 3. chest pain: vết thương ngực

> 4. resting blood pressure : huyết áp

> 5. serum cholestoral in mg/dl : Nồng độ cholestoral trong máu

> 6. fasting blood sugar > 120 mg/dl: lượng đường huyết

> 7. resting electrocardiographic results (values 0,1,2): kết quả điện tâm đồ

> 8. maximum heart rate achieved: Nhịp tim lớn nhất

> 9. exercise induced angina :Chứng đau thắt ngực

> 10. oldpeak = ST depression induced by exercise relative to rest

> 11. the slope of the peak exercise ST segment

> 12. number of major vessels (0-3) colored by flourosopy

> 13. thal: 3 = normal; 6 = fixed defect; 7 = reversable defect

Cột cuối là Target có giá trị là 0 (không có bệnh) và 1 (có mầm móng bệnh ung thư)

Tiếp theo là load dữ liệu

```
dataset = pd.read_csv('Dataset\heart.csv')
# split into input (X) and output (Y) variables
X = dataset.iloc[:,0:13]
Y = dataset.iloc[:,13]
```

Ở đây sử dụng thư viện Pandas để load dữ liệu

Các dữ liệu của feature được lấy từ 0 đến cột thứ 13 và riêng label được lấy ở cột cuối.

Thiết lập Model

Keras có 2 cách sử dụng để thiết lập Model đó chính là sử dụng Sequential Model và API Model. Với Project của chúng em đã sử dụng Sequential Model

Model trong Keras được thiết lập bởi những layers nối tiếp nhau. Vì thế chúng em tạo một Model tuần tự và thêm vào từng lớp cho đến khi chúng ta cảm thấy hài lòng.

Đầu tiên phải chắc chắn rằng lớp input layers khớp với số lượng feature ta đưa vào.

Trong trường hợp này, chúng em khởi tạo những network weight là những số nhỏ ngẫn nhiên từ 0 đến 0.05 bởi vì đây là mặc định của Keras. Một cách khác là có thể khởi tạo từ Gaussian.

Chúng em sử dụng activation 'relu' cho 2 layers đầu tiên và hàm sigmoid cho layer output. Bởi vì để cải thiện tốt hơn về mặt hiệu suất

Sigmoid ở output layer sẽ chắc sẵn rằng ouput của chúng ta sẽ nằm trong khoảng từ 0 – 1 và dễ dàng để ánh xạ tới kết quả trong thực tế hơn đơn gian là vì đồ thị của hàm sigmoid chỉ biến thiên từ 0 – 1

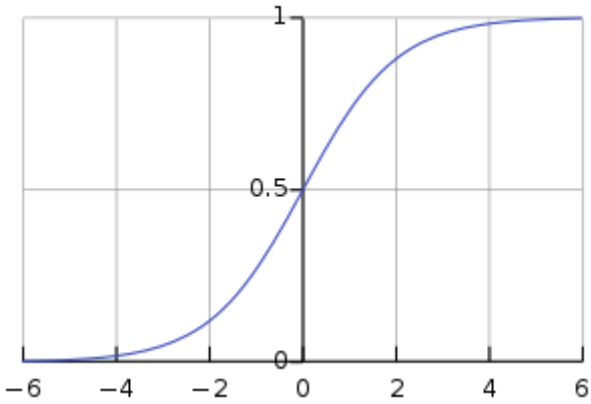

Dưới đây là đoạn code xây dựng Model:

```
# create model
model = Sequential()
model.add(Dense(16, input_dim=13, activation='relu'))
model.add(Dense(12, activation='relu'))
model.add(Dense(1, activation='sigmoid'))
plot_model(model, to_file='model_plot.png', show_shapes=True, show_layer_names=True)
```

Và được thể hiện dưới dạng hình ảnh sau:

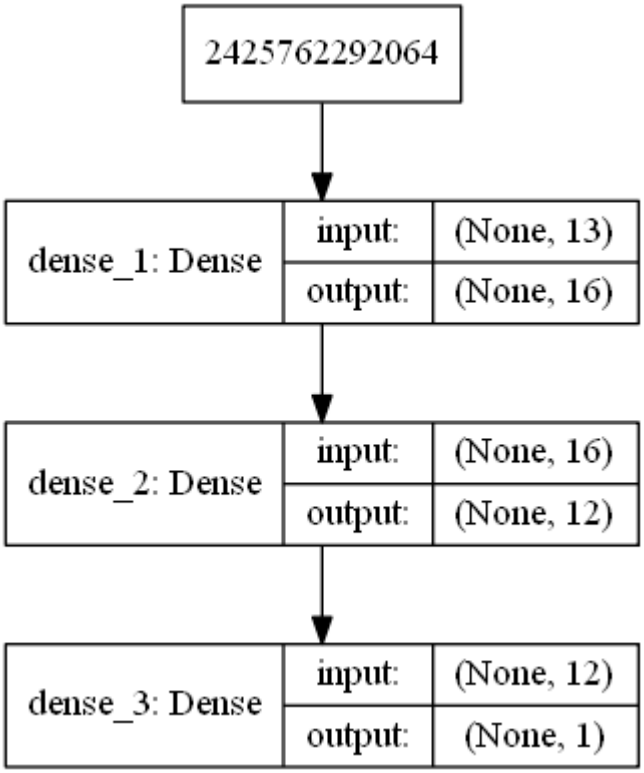

Hình 20. Sơ đồ hiện thực Model

Compile Model

```
# Compile model
model.compile(loss='binary_crossentropy', optimizer='adam', metrics=['accuracy'])
```

Quá trình compile sẽ lựa chọn cách tốt nhất để thể hiện mạng lưới neuron để trainning dữ liệu và thực hiện predcit dữ liệu.

Trong quá trình compile chúng ta cần xác định vài thuộc tính sử dụng cho quá trình training.

Ở đây, chúng em sử dụng loss function có tên “binary_crossentropy” và sử dụng giải thuật gradient descent có tên “adam”. Cuối cùng, do mục đính chúng ta là phân loại dữ liệu nên việc thu thập và báo cáo lại độ chính xác trong mỗi lần traning tập dữ liệu là điều cần thiết vì thế chúng em sử dụng metrics= ”accuracy”

Train Model

```
# Fit the model
model.fit(X, Y, epochs=300, batch_size=20)
```

Bắt đầu chạy dữ liệu trên model chúng ta đã thiết lập, ở đây có một số qui định cho quá trình training như sau:

Epochs=300: số lần chạy hết qua dữ liệu là 300 lần

Batch-size: giới hạn dữ liệu chạy 1 lần là 20

Đánh giá Model

Sau khi Model đã được train chúng ta tiến hành đánh giá hiệu suất của mạng nơ ron chúng ta vừa mới tạo ra trên chính tập dữ liệu chúng ta sử dụng để trainning

```
# evaluate the model
scores = model.evaluate(X, Y)
print("scores: \n%s: %.2f%%" % (model.metrics_names[1], scores[1]*100))
```

Kết quả in ra score càng gần với 1 chứng tỏ model chúng ta đã train là tốt

Dự đoán dữ liệu

Để dự đoán dữ liệu chỉ cần sử dụng hàm Predict

```
# round predictions
predictions = model.predict(DataInput)
rounded = [round(x[0]) for x in predictions]
```

Tuy nhiên khi dự đoán dữ liệu sẽ có kết quả là một dãy số trong khoảng [0,1]

Vì đây là bài toán Binary Classification nên đầu ra của dự đoán chỉ có thể là 1 hoặc 0 vì thế ở đây chúng ta sử dụng hàm Roud để làm tròn dữ liệu.

BẢNG PHÂN CÔNG CÔNG VIỆC

STT	Họ và tên	Công việc
1	Đào Xuân Thủy	- Tìm hiểu và viết chương trình ví dụ và báo cáo về Polynomial Regression. - Tìm hiểu và viết chương trình ví dụ và báo cáo về Logistic Regression.
2	Lâm Phước Bảo	- Tìm hiểu và viết chương trình ví dụ và báo cáo về Multivariate Linear Regression. - Tìm hiểu và viết chương trình ví dụ và báo cáo về Newral Networks.

PHỤ LỤC

1. Scikit-learn

Scikit-learn (trước đây là scikits.learn) là một thư viện học máy miễn phí cho ngôn ngữ lập trình Python. Nó có các thuật toán phân loại, hồi quy và phân cụm khác nhau bao gồm hỗ trợ vectơ, random forests, gradient boosting, k-means và DBSCAN, và được thiết kế để tương tác với các thư viện khoa học và số học Python NumPy và SciPy. [1]

2. Pandas

Trong lập trình máy tính, pandas là một thư viện phần mềm được viết cho ngôn ngữ lập trình Python để thao tác và phân tích dữ liệu. Cụ thể, nó cung cấp các cấu trúc dữ liệu và các thao tác để thao tác trên mảng các số và chuỗi thời gian. Đây là phần mềm miễn phí được phát hành theo giấy phép BSD. Tên được lấy từ thuật ngữ "panel data", thuật ngữ kinh tế lượng cho các tập dữ liệu bao gồm việc quan sát một cá thể trong nhiều khoảng thời gian. [7]

3. Numpy

NumPy là một thư viện cho ngôn ngữ lập trình Python, hỗ trợ tính toán cho các mảng và ma trận lớn, đa chiều, cùng với một tập hợp lớn các hàm toán học cấp cao để tính toán trên các mảng này. Tổ tiên của NumPy là Numeric, ban đầu được tạo ra bởi Jim Hugunin với sự đóng góp từ một số nhà phát triển khác. [6]

4. Matplotlib

Matplotlib là một thư viện vector cho ngôn ngữ lập trình Python và là phần mở rộng toán học NumPy. Nó cung cấp API hướng đối tượng để nhúng các ô vào các ứng dụng bằng cách sử dụng các bộ công cụ GUI đa năng như Tkinter, wxPython, Qt hoặc GTK+. Ngoài ra còn có một giao diện "pylab" dựa trên một máy trạng thái (như OpenGL), được thiết kế gần giống với MATLAB. [4]

5. OS

Trong python cung cấp các chức năng để tương tác với hệ điều hành. Os là một module cung cấp các chức năng dùng để giao tiếp với hệ điều hành hệ điều hành. Các mô-đun * os * và * os.path * bao gồm các chức năng để tương tác với các tệp, cây thư mục trong hệ thống.

6. Keras

Keras là một library được phát triển vào năm 2015 bởi François Chollet, là một kỹ sư nghiên cứu deep learning tại google. Nó là một open source cho neural network được viết bởi ngôn ngữ python. keras là một API bậc cao có thể sử dụng chung với các thư viện deep learning nổi tiếng như tensorflow (được phát triển bởi gg), CNTK (được phát triển bởi microsoft), Theano (người phát triển chính Yoshua Bengio). Keras có một số ưu điểm như: [5]

Dễ sử dụng, xây dựng model nhanh.

Có thể run trên cả cpu và gpu

Hỗ trợ xây dựng CNN, RNN và có thể kết hợp cả 2.

Cấu trúc:

Cấu trúc của keras chúng ta có thể chia ra thành 3 phần chính:

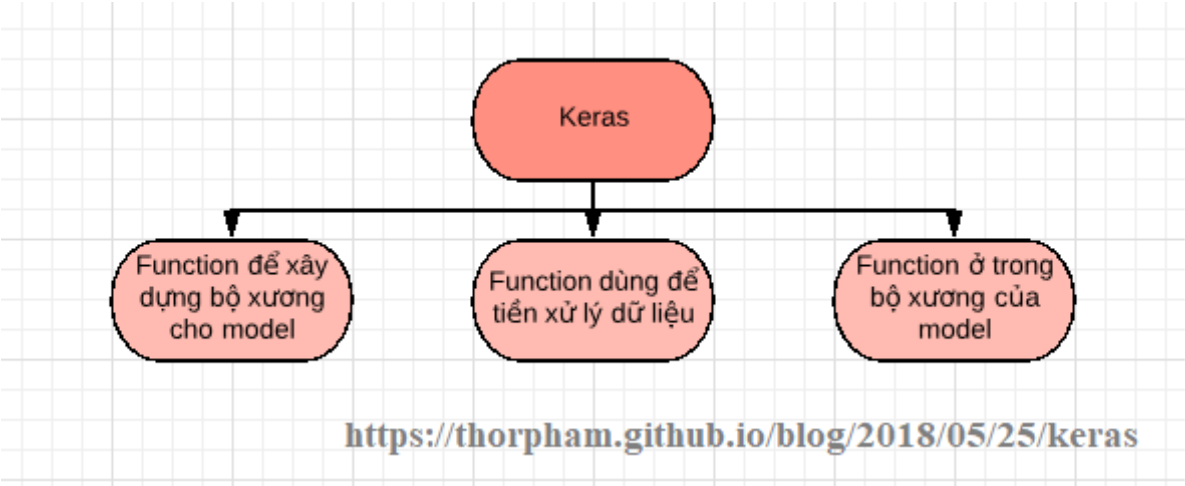

Hình 21. Thành phần của keras

Module dùng để xây dựng bộ xương cho model:

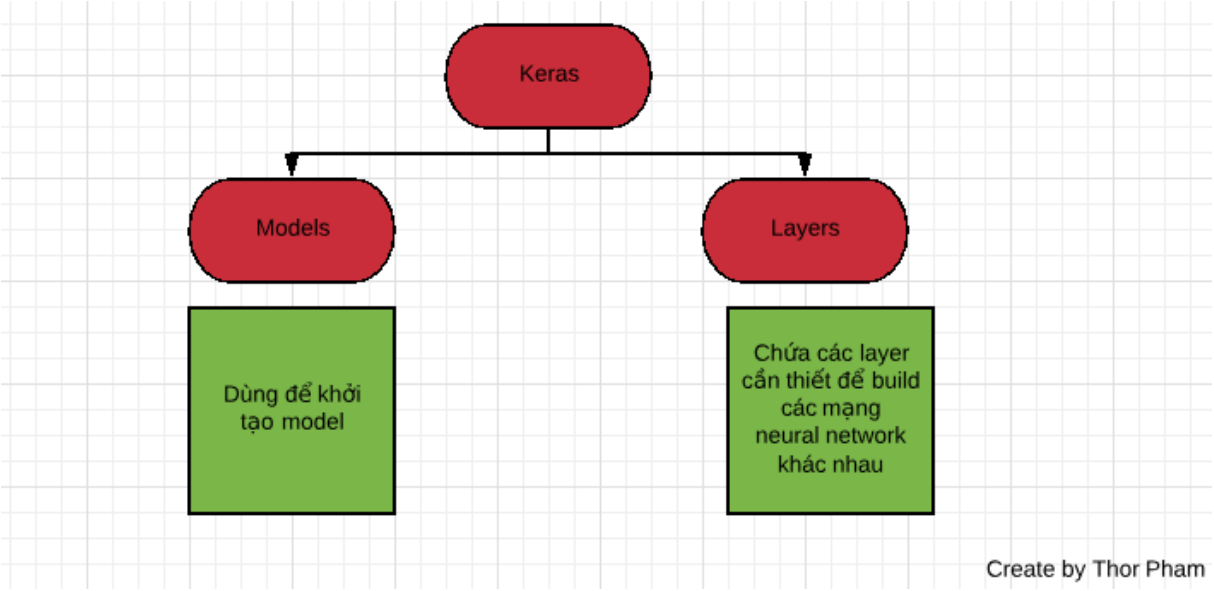

Hình 22. Module xây dựng Keras

TÀI LIỆU THAM KHẢO

[1] David Cournapeau, *scikit-learn*, Scientific software in Python, https://en.wikipedia.org/wiki/Scikit-learn, 05/05/2019.

[2] Hau Nguyen, *Binary logistic regression (hồi quy logistic)*, Học máy cho người Việt, http://ml4vn.blogspot.com/2017/08/bai-7-binary-logistic-regression-hoi.html, 07/08/2017.

[3] Hồ Sỹ Hùng, *Tóm lược lịch sử phát triển của ngành Machine Learning*, https://techmaster.vn/posts/33923/lich-su-phat-trien-machine-learning, 09/06/2016.

[4] John D. Hunter, *Matplotlib*, Scientific software in Python, https://en.wikipedia.org/wiki/Matplotlib, 26/02/2019.

[5] Thong Pham, *Tìm hiểu về thư viện keras trong deep learning*, Deep Learing Tutotials, https://thorpham.github.io/blog/2018/05/25/keras/, 25/05/2018.

[6] Travis Oliphant, *NumPy*, Scientific software in Python, https://en.wikipedia.org/wiki/NumPy, 14/04/2019.

[7] Wes McKinney, *pandas (software)*, Scientific software in Python, https://en.wikipedia.org/wiki/Pandas_(software), 28/04/2019.